



构建生产级RAG实战工作坊

2026 年 3 月



© 2025 Thoughtworks | Confidential



RAG技术全景 (1/5)

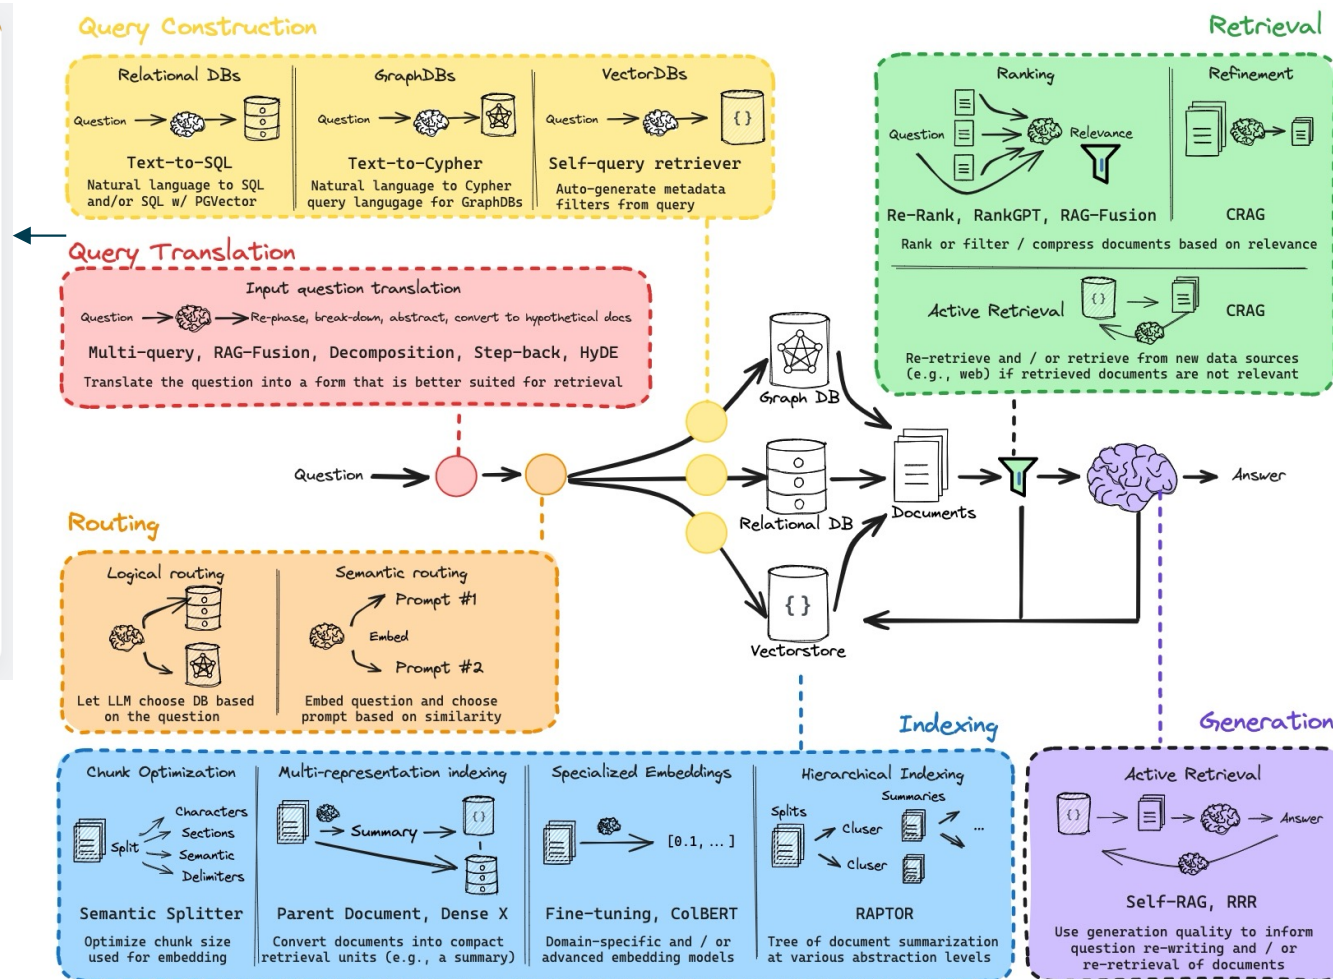
1. 查询处理 (Query)

• 查询翻译 (Translation)

改写、拆解或抽象问题。包括 Multi-query, RAG-Fusion, Step-back 提示词, HyDE (假设性文档嵌入)。

• 查询构建 (Construction)

自然语言转结构化查询: Text-to-SQL (关系型), Text-to-Cypher (图数据库), 自动生成元数据过滤条件 (Self-query)。



RAG技术全景 (2/5)

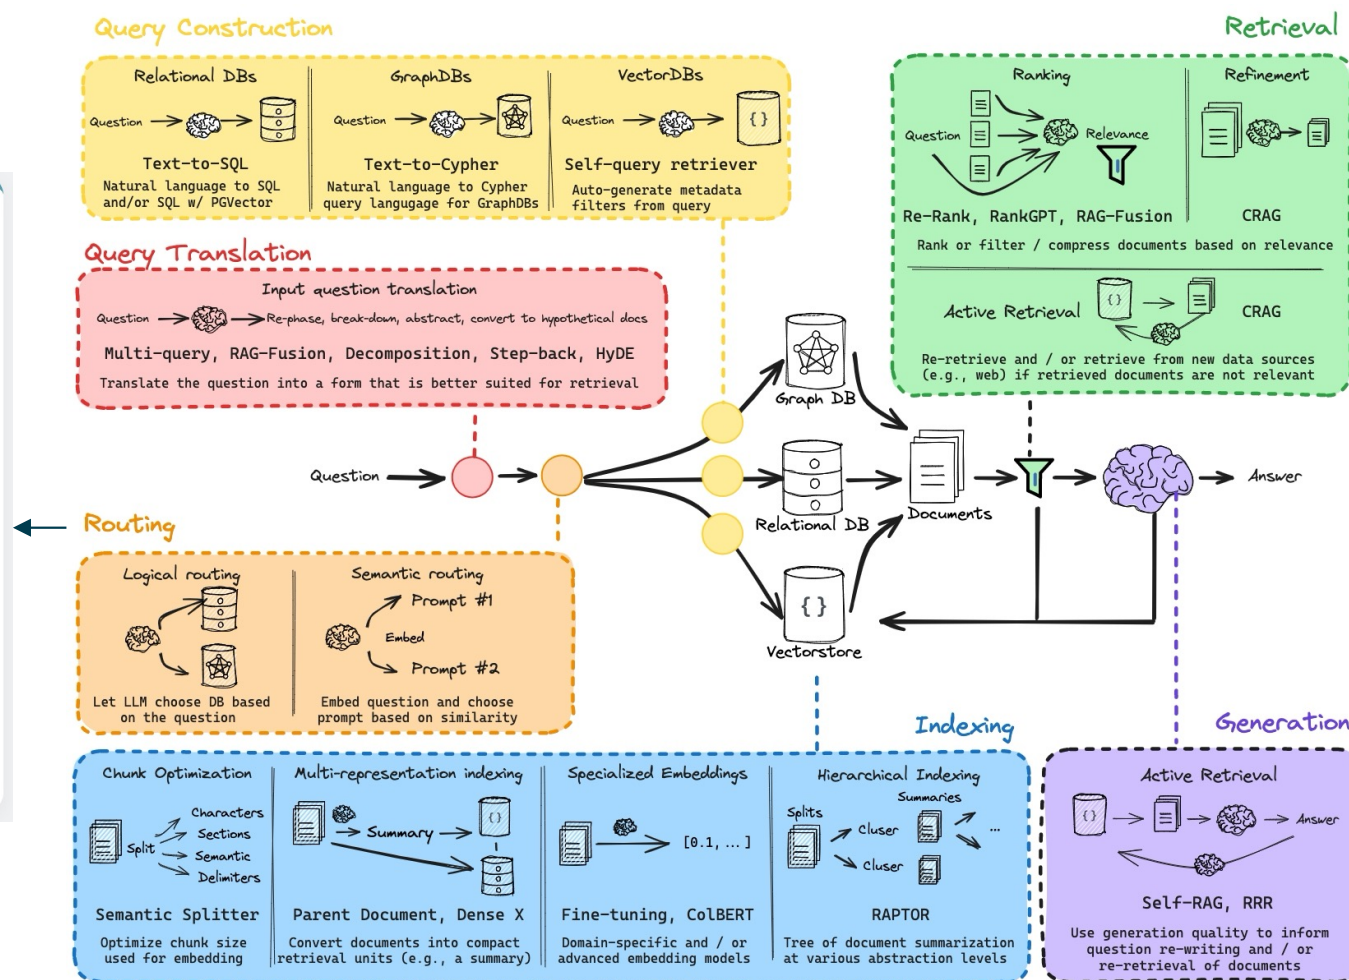
2. 路由 (Routing)

• 逻辑路由 (Logical Routing)

让大模型 (LLM) 根据自然语言问题自主判断并选择合适的底层数据库进行查询。

• 语义路由 (Semantic Routing)

对输入问题进行向量化嵌入，根据相似度自动匹配预设的最优 Prompt 或处理管道。



RAG技术全景 (3/5)

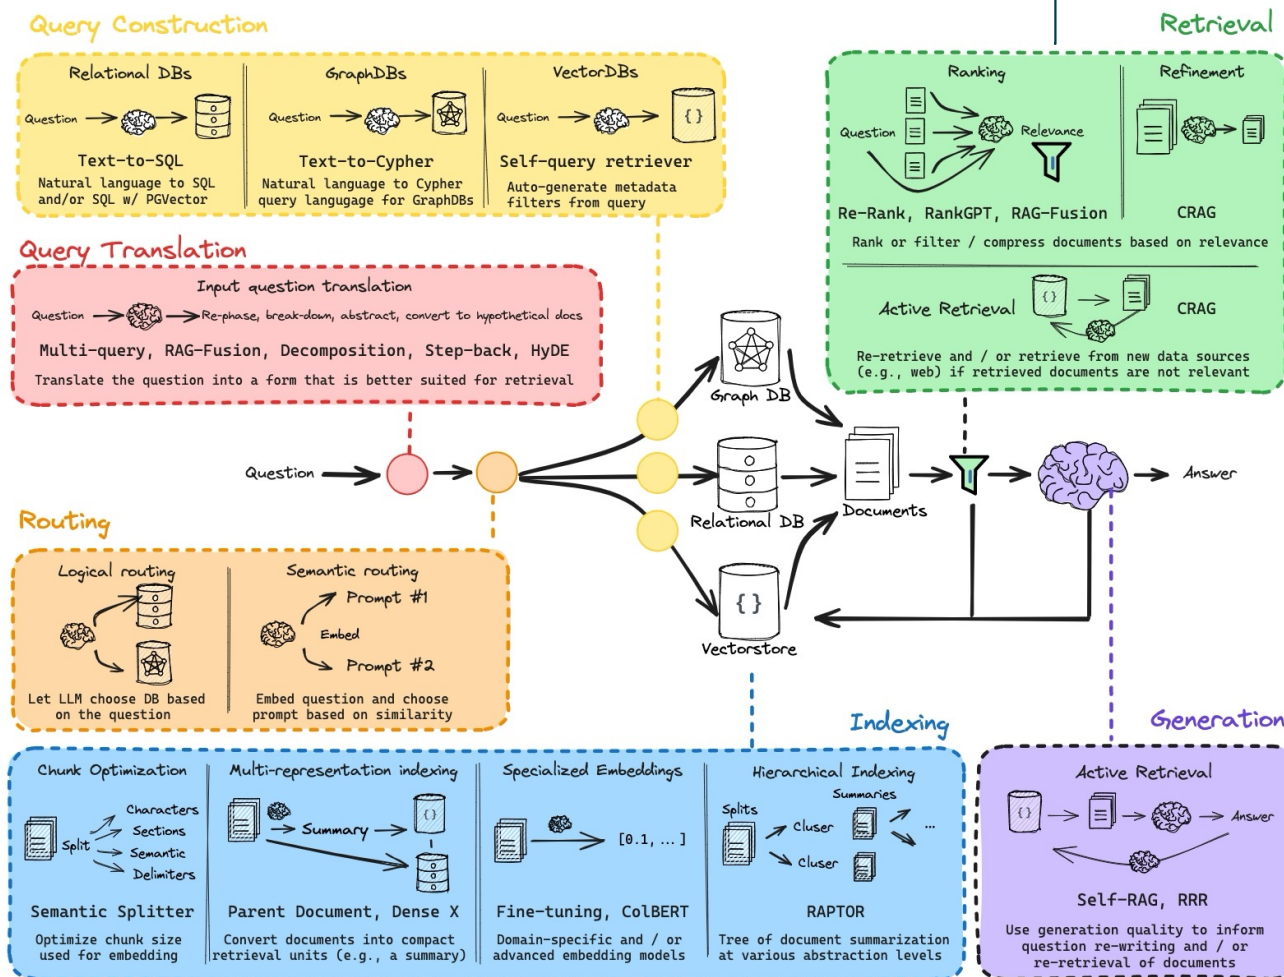
3. 检索 (Retrieval)

• 重排与过滤 (Ranking)

利用 Re-Rank模型, RankGPT 等对初步召回的文档进行相关性二次打分、过滤或压缩。

• 主动检索 (Active Retrieval)

如 CRAG 技术, 评估检索质量, 若文档不相关则触发重试或切换数据源 (如请求Web搜索)。



RAG技术全景 (4/5)

4. 索引构建 (Indexing) & 数据准备

• 分块优化 (Chunk Optimization)

调整文档块大小，按字符、段落或语义切分 (Semantic Splitter)，适配 Embedding 模型限制。

• 多表示索引 (Multi-representation)

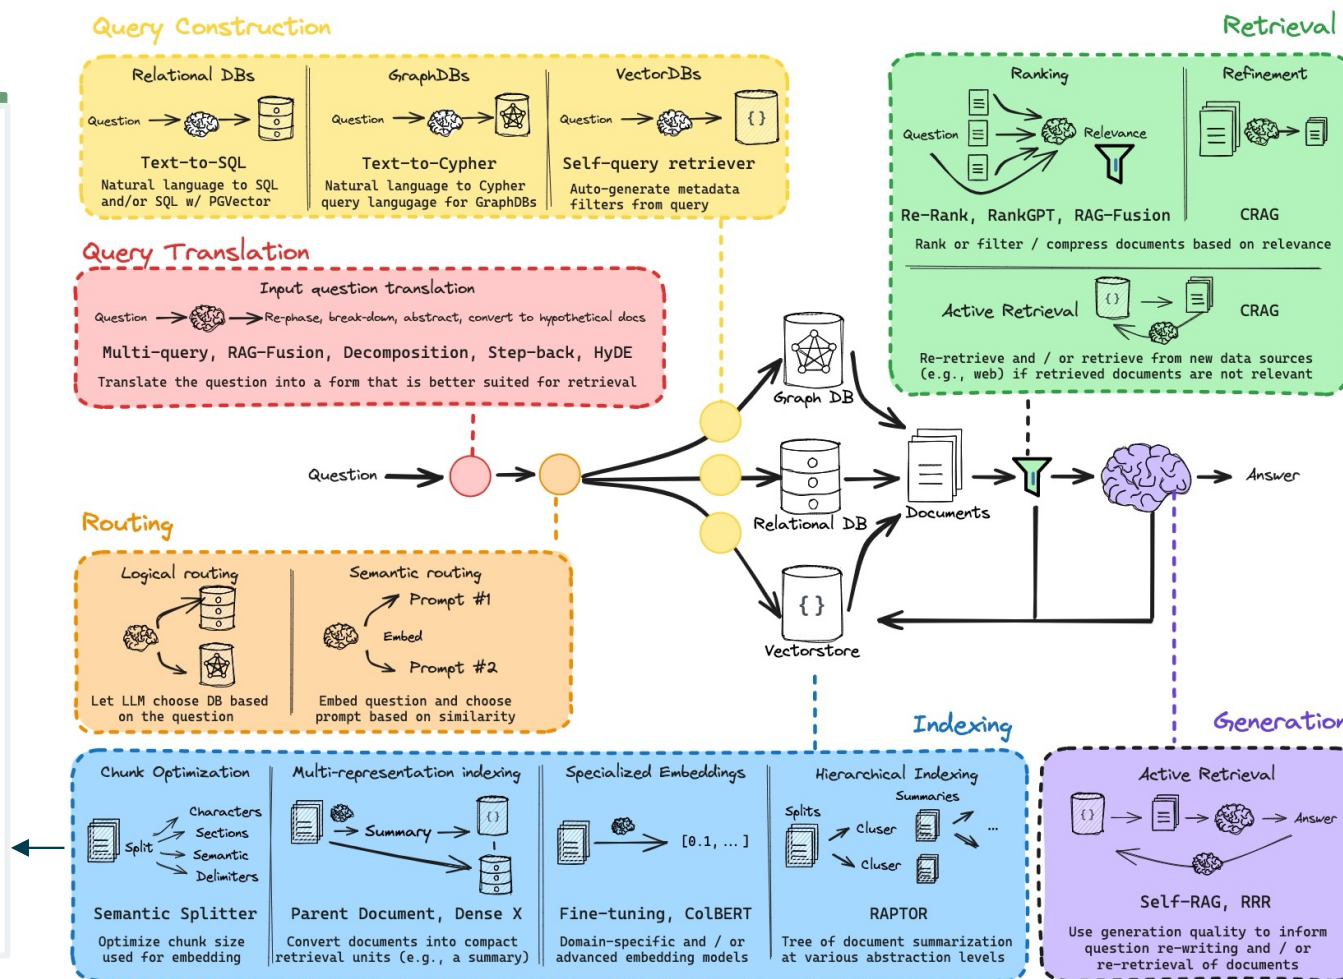
长文档转紧凑检索单元：如父子文档检索 (Parent Document)、摘要检索映射回原文档。

• 专用向量嵌入 (Specialized Embeddings)

应用领域微调模型或高级模型（如 ColBERT）以提升特定文本特征的代表能力。

• 层级索引 (Hierarchical Indexing)

如 RAPTOR 结构，建立自底向上的树状文档总结与聚类，支持在不同抽象层级上检索。



RAG技术全景 (5/5)

5. 生成 (Generation)

- 上下文整合

将检索到的 Top-K 文档作为增强上下文，无缝注入到 LLM 的 Prompt 中。

- 自我反思 (Self-RAG / RRR)

在生成过程中，模型评估自身输出质量，按需主动重写问题、触发二次检索或重新读取数据，直至答案达标。

